

Выборки

Определение

Выборка

— подмножество генеральной совокупности

Определение

Семплирование

— способ получения выборки

Важно

В зависимости от семплирования выводы о генеральной совокупности по выборке могут очень сильно отличаться

- Пусть у нас есть генеральная совокупность
- Из нее мы можем выделить множество различных выборок
- Семплирование - способ получения выборки
- "какая выборка вероятнее всего получится, если формировать ее определенным образом"

Семплирование - правило, которое для каждой выборки возвращает вероятность ее получения при определенном алгоритме выбора

Определение

Семплирование как распределение

— вероятностное распределение на множестве всех возможных выборок фиксированного размера из генеральной совокупности.

Таким образом, первое определение это **алгоритм формирования выборки**, а второе - **результат его применения**

Важно

если ты проводишь семплирование, ты можешь предсказать, **насколько вероятно** получить ту или иную выборку, но **не можешь точно сказать, какая именно окажется в твоих руках**.

Однако есть и неслучайное семплирование, когда итоговая выборка определяется однозначно.

Систематическая ошибка семплирования

Определение

Систематическая ошибка приближения среднего (смещенная оценка)

— разность между матожиданием выборочного среднего и средним в генеральной совокупности

$$\text{Bias} = \mathbb{E}(\bar{X}) - \mathbb{E}X$$

Если $\mathbb{E}(\bar{X}) = \mathbb{E}X$, систематической ошибки нет.

Пример

Истинное распределение роста людей — нормальное ($\mu=175\text{см}$), но мы измеряем только спортсменов-баскетболистов, чей средний рост выше. Оценка среднего будет **систематически завышена**.

Важно

Отсутствие систематической ошибки (несмещённость) — это хорошо, но **не гарантирует точности оценки**, если при этом велика **случайная ошибка (дисперсия)**. В таких случаях оценка может быть «в среднем правильной», но на практике сильно варьироваться от выборки к выборке.

Пример

Вы хотите купить арбуз весом около 5 кг. У вас есть два друга, которые помогают оценить вес — на глаз или на ручных весах.

- **Анна** — никогда не обманывает, но очень неровно оценивает вес:
- В среднем она правильна (не завышает и не занижает),
- Но может сказать «4 кг», когда на самом деле 6 кг, или «7 кг» при 3 кг. → Её оценки **без систематической ошибки**, но с **большой дисперсией**.
- **Борис** — немного консервативен:
- Всегда говорит «на пару сотен грамм меньше», чем на самом деле,
- Зато почти всегда **попадает в предел ± 100 грамм**. → Его оценки **имеют небольшое смещение**, но **очень малую дисперсию**.

Вычисление в Python методом Монте-Карло (см. далее):

```
means = [df.sample(n=10)['value'].mean() for _ in range(10_000)]
bias = np.mean(means) - population_mean
```

Определение

Маргинальная ошибка семплирования (margin of error)

— мера точности оценки, указывает насколько может отличаться выборочное среднее от среднего по генеральной совокупности с заданной вероятностью

$$P(|\bar{X} - \mathbb{E}X| \leq ME) = p,$$

где ME - маргинальная ошибка, p - уровень доверия

Пример

Маргинальная ошибка 3 при уровне доверия 95% означает, что истинная доля в генеральной совокупности с вероятностью 95% лежит между $\mu - 3$ и $\mu + 3$

Вычисление в Python методом Монте-Карло:

```
mc_means = np.array([df.sample(100)['spend'].mean() for _ in range(5000)])
me_95 = np.percentile(np.abs(mc_means - true_mean), 95)
print(f"Margin of error (95%): {me_95:.2f}")
```

Виды систематических ошибок

- **СО выжившего** - в выборке оказывается много наблюдений из одной группы объектов, которую условно называют «выжившие»
- **Черри-пикинг** - в выборку взяты те наблюдения, которые доказывают выводы исследователя, зато проигнорированы те, которые опровергают
- **СО самоотбора** - в выборку взяли тех, кто сам пожелал войти в неё
- **Систематическая ошибка недостаточного охвата отдельных частей генеральной совокупности (undercoverage bias)** - некоторые сегменты генеральной совокупности в выборке практически не представлены или представлены в меньшей пропорции, чем в генеральной совокупности. Если у таких объектов какая-то характеристика выше, чем у представленных, то выборочное значение будет систематически ниже, чем в генеральной совокупности.

Виды семплирования

- простое случайное семплирование
- случайное семплирование с возвращением
- стратифицированное случайное семплирование

Простое случайное семплирование

Определение

Простое случайное семплирование (SRS)

— семплирование, при котором все выборки из n наблюдений с учетом порядка и без возвращений равновероятны

Учет порядка нужен, чтобы быть уверенным в равновероятности выборки, он используется только на этапе формирования выборок.

Алгоритм

Получение SRS

1. По исходной генеральной совокупности строим генеральную совокупность всех возможных выборок без повторения из n наблюдений с учётом порядка
2. Из этого набора равновероятно выбираем одну выборку

В Python:

```
df.sample(n)
```

Случайное семплирование с возвращением

Определение

Случайное семплирование с возвращением (RS)

— семплирование, при котором все выборки из n наблюдений с учетом порядка и возможным повторением элементов равновероятны

- алгоритм построения аналогичный

В Python:

```
df.sample(n, replace=True)
```

Лемма

Сравнение семплирования с возвращением и простого случайного

Если размер выборки намного меньше размера генеральной совокупности (эмпирически - если $n < 0,01 \cdot N$), то семплирование с возвращением и простое случайное семплирование приблизительно одинаковы

Объяснение

Пусть мы выбираем без возвращения один элемент за другим из огромной генеральной совокупности. Формально в ней становится меньше элементов, но из-за большого размера их остаётся всё ещё много: генеральная совокупность почти не меняется. Поэтому нет существенной разницы: возвращать или не возвращать очередной элемент выборки в генеральную совокупность.

Случайная выборка со стратификацией

Определение

Страта

— конечное подмножество генеральной совокупности, соответствующее одному из уровней фактора стратификации

Определение

Стратификация

— представление генеральной совокупности в виде дизъюнктного объединения страт

Определение

Фактор стратификации

— характеристика наблюдений, по значениям которой происходит разбиение на страты.

Интерпретация

Страта — это однородная подгруппа (слой) генеральной совокупности, выделенная по определённому признаку, который считается значимым для анализа.

Зачем это нужно?

1. Уменьшить дисперсию оценок (внутри страты объекты однороднее),
2. Обеспечить представительность (гарантировать, что каждый тип учтён),
3. Позволить отдельный анализ по группам (например, сравнить эффективность по классам техники).

Определение

Случайное семплирование со стратификацией (stratified random sampling)

— семплирование, при котором равновероятны все выборки из n наблюдений с учётом порядка без повторения элементов, для которых доля каждой страты в выборке совпадает с долей этой страты в генеральной совокупности (с точностью до округления)

📄 Алгоритм

📖 Получение стратифицированной выборки

1. Для каждой страты вычисляем требуемое количество наблюдений из этой страты в выборке $n_i = n \cdot P(\text{Stratum}_i)$
2. Из каждой страты получаем подвыборку нужного размера простым случайным семплированием.
3. Объединяем подвыборки в выборку.

В Python:

```
def stratified_sample(df, strata_col, n):  
    # Пропорциональная стратификация: сколько строк брать из каждой страты  
    def sample_group(x):  
        # Доля страты в общем объёме  
        group_size = len(x)  
        # Пропорциональный размер выборки из этой страты  
        sample_size = int(round(group_size / len(df) * n))  
        # Берём минимум, чтобы избежать проблем с малыми группами  
        return x.sample(min(sample_size, group_size))  
  
    result = df.groupby(strata_col).apply(sample_group)  
    return result.reset_index(drop=True)
```

⚠️ Важно

- Если n_i целые, то CO нет, однако если они дробные, то приходится округлять до целых.
- Если округлять вниз, то количество наблюдений будет меньше требуемого, если вверх, то больше
- Так или иначе появится некоторая CO, однако маргинальная ошибка все равно уменьшится по сравнению с SRS

Стратифицированное семплирование заметно точнее простого случайного, если разброс значений внутри страт заметно меньше разброса среди всех значений в генеральной совокупности

Метод Монте-Карло

Определение

Эксперимент Монте-Карло

1. случайная генерация одной выборки в соответствии с семплированием
2. проверка, случилось ли в выборке событие или вычисление описательной статистики
3. сохранение результата для этой выборки.

Определение

Метод Монте-Карло

— это проведение M случайных экспериментов Монте-Карло и дальнейшая обработка их результатов

В Python с SRS:

```
np.random.seed(42)
M = 10_000
count = 0
for _ in range(M):
    df_sample = df.sample(n=2) # SRS
    if df_sample['Пост'].mean().astype(int) == 170: # событие случилось
        count = count + 1 # считаем количество
print(count / M)
```

Цель метода Монте-Карло

Аппроксимировать теоретические вероятности и распределения с помощью частоты на большом числе симуляций.

Лемма

Точность метода Монте-Карло

Эмпирическое правило: если увеличить в 100 раз размер выборки и она всё ещё останется маленькой ($10n < 0,01 \cdot N$), то точность возрастёт в 10 раз, но для больших выборок увеличение размера в k раз повышает точность больше чем в \sqrt{k} раз.

tags: #flashcardsSTAT

Что такое Выборка?

%

— подмножество генеральной совокупности

Что такое Семплирование?

%

— способ получения выборки

Что такое Семплирование как распределение?

%

— вероятностное распределение на множестве всех возможных выборок фиксированного размера из генеральной совокупности.

Систематическая ошибка семплирования

Что такое Систематическая ошибка приближения среднего (смещенная оценка)?

%

— разность между матожиданием выборочного среднего и средним в генеральной совокупности

$$\text{Bias} = \mathbb{E}(\bar{X}) - \mathbb{E}X$$

Если $\mathbb{E}(\bar{X}) = \mathbb{E}X$, систематической ошибки нет.

Что такое Маргинальная ошибка семплирования (margin of error)?

%

— мера точности оценки, указывает насколько может отличаться выборочное среднее от среднего по генеральной совокупности с заданной вероятностью

$$P(|\bar{X} - \mathbb{E}X| \leq ME) = p,$$

где ME - маргинальная ошибка, p - уровень доверия

Виды семплирования

Что такое Простое случайное семплирование (SRS)?

%

— семплирование, при котором все выборки из n наблюдений с учетом порядка и без возвращений равновероятны

Что такое Получение SRS?

%

1. По исходной генеральной совокупности строим генеральную совокупность всех возможных выборок без повторения из n наблюдений с учётом порядка
2. Из этого набора равновероятно выбираем одну выборку

Что такое Случайное семплирование с возвращением (RS)?

%

— семплирование, при котором все выборки из n наблюдений с учетом порядка и возможным повторением элементов равновероятны

- алгоритм построения аналогичный

Сформулируйте лемму: Сравнение семплирования с возвращением и простого случайного

%

Если размер выборки намного меньше размера генеральной совокупности (эмпирически - если $n < 0,01 \cdot N$), то семплирование с возвращением и простое случайное семплирование приблизительно одинаковы

Что такое Страта?

%

— конечное подмножество генеральной совокупности, соответствующее одному из уровней фактора стратификации

Что такое Стратификация?

%

— представление генеральной совокупности в виде дизъюнктного объединения страт

Что такое Фактор стратификации?

%

— характеристика наблюдений, по значениям которой происходит разбиение на страты.

Что такое Случайное семплирование со стратификацией (stratified random sampling)?

%

— семплирование, при котором равновероятны все выборки из n наблюдений с учётом порядка без повторения элементов, для которых доля каждой страты в выборке совпадает с долей этой страты в генеральной совокупности (с точностью до округления)

Что такое Получение стратифицированной выборки?

%

1. Для каждой страты вычисляем требуемое количество наблюдений из этой страты в выборке $n_i = n \cdot P(\text{Stratum}_i)$
2. Из каждой страты получаем подвыборку нужного размера простым случайным семплированием.
3. Объединяем подвыборки в выборку.

Метод Монте-Карло

Что такое Эксперимент Монте-Карло?

%

1. случайная генерация одной выборки в соответствии с семплированием
2. проверка, случилось ли в выборке событие или вычисление описательной статистики

3. сохранение результата для этой выборки.

Что такое Метод Монте-Карло?

%

— это проведение M случайных экспериментов Монте-Карло и дальнейшая обработка их результатов

Сформулируйте лемму: Точность метода Монте-Карло

%

Эмпирическое правило: если увеличить в 100 раз размер выборки и она всё ещё останется маленькой ($10n < 0,01 \cdot N$), то точность возрастет в 10 раз, но для больших выборок увеличение размера в k раз повышает точность больше чем в \sqrt{k} раз.

Что такое неслучайное семплирование?

%

— семплирование, при котором одна выборка имеет вероятность 100%, все остальные — 0%.

Почему undercoverage bias не зависит от размера выборки?

%

— потому что он вызван **отсутствием или недоучётом целых сегментов** генеральной совокупности. Даже огромная выборка будет смещённой, если она не включает важную группу.

Как влияет размер выборки на точность Монте-Карло?

%

— увеличение числа симуляций M повышает точность оценки \sim на \sqrt{M} . Чтобы ошибка уменьшилась в 10 раз, нужно увеличить M в 100 раз.

Как получить простую случайную выборку (SRS) в pandas?

%

```
df.sample(n=100)
```

◆ По умолчанию `replace=False` и `random_state` не фиксирован.

✓ Для воспроизводимости добавьте `random_state`:

```
df.sample(n=100, random_state=42)
```

Как получить случайную выборку с возвращением (RS)?

%

```
df.sample(n=100, replace=True, random_state=42)
```

◆ `replace=True` позволяет одному наблюдению попасть в выборку несколько раз.

Как реализовать стратифицированное семплирование по столбцу `strata_col`?

%

```
def stratified_sample(df, strata_col, n_total):
    return (
        df.groupby(strata_col)
        .sample(frac=n_total/len(df), replace=False)
        .sample(frac=1, random_state=42) # перемешать в конце
    )
```

- ◆ `frac=n_total/len(df)` — доля от каждой страты.
- ◆ Второй `.sample(frac=1)` — перемешивает объединённую выборку.
- ▲ При округлении может быть небольшая ошибка покрытия.

Как провести эксперимент Монте-Карло для оценки среднего?
%

```
np.random.seed(42)
M = 10_000
mc_means = []

for _ in range(M):
    sample = df.sample(n=200)
    mc_means.append(sample['value'].mean())

# Теперь можно анализировать распределение mc_means
```

- ✓ Цель: оценить поведение выборочного среднего при многократном повторении выборки.

Как вычислить маргинальную ошибку (margin of error) методом Монте-Карло?
%

```
true_mean = df['value'].mean() # или известно из условия
errors = np.abs(np.array(mc_means) - true_mean)
me_90 = np.percentile(errors, 90) # ME с вероятностью 90%
print(f"Margin of error (90%): {me_90:.2f}")
```

- 🔗 Это эмпирическая оценка:

$$P(|\bar{X} - \mathbb{E}X| \leq ME) = 0.9$$

Как проверить, есть ли систематическая ошибка у семплирования?
%

```
bias = np.mean(mc_means) - true_mean
print(f"Bias: {bias:.3f}")
```

✓ Если $\text{bias} \approx 0$ — систематической ошибки нет.

◆ Полезно сравнивать для разных методов (SRS, RS, стратификация).

Как написать стратифицированную выборку с контролем размера подвыборки?
%

```
def stratified_sample_exact(df, strata_col, n_total):
    props = df[strata_col].value_counts(normalize=True)
    n_strata = (props * n_total).round().astype(int)

    # Корректировка суммы
    while n_strata.sum() != n_total:
        diff = n_total - n_strata.sum()
        idx = np.random.choice(n_strata.index)
        n_strata[idx] += np.sign(diff)

    return df.groupby(strata_col, group_keys=False).apply(
        lambda x: x.sample(n=n_strata[x.name], random_state=42)
    )
```